

UNIVERSIDAD DEL VALLE DE GUATEMALA
Facultad de Ingeniería



Laboratorio 2
Clasificación de Malware

Sofía Velasquez, 22049
Sebastián Huertas, 22295

Jorge Andres Yass
Security Data Science
Guatemala, 2026

Repositorio Github

<https://github.com/xtsebas/Security-Data-Science.git/>


Inciso 3.1

lab2/[modelo1_malware.ipynb](#)

Descripción del modelo:

Modelo 1: TF-IDF + Random Forest

Este modelo utiliza la representación TF-IDF (Term Frequency–Inverse Document Frequency) sobre las secuencias de API calls, tratando cada secuencia como un documento de texto. El vector TF-IDF captura la importancia relativa de cada API en el contexto de todas las muestras. El clasificador final es un Random Forest, un método de ensemble robusto. La partición fue 70% entrenamiento (1,799 muestras) y 30% prueba (771 muestras), con validación cruzada de 10 folds.





Inciso 3.2

lab2/[modelo2_malware_embeddings.ipynb](#)

Modelo 2: Gemini Embeddings + Red Neuronal

Este modelo aprovecha embeddings semánticos generados por el modelo de lenguaje Gemini (google/text-embedding-004), con task type CLASSIFICATION. Los embeddings capturan representaciones densas de alta dimensionalidad de las secuencias de API calls. Estos vectores de embedding son utilizados como entrada de una red neuronal profunda entrenada para clasificación binaria (Benigno/Malware).



Comparación de Métricas

La siguiente tabla consolida las métricas clave de ambos modelos según los resultados obtenidos:

Métrica	Modelo 1 (Benigno)	Modelo 1 (Malware)	Modelo 2 (Benigno)	Modelo 2 (Malware)
Precision	0.95	0.99	0.90	0.98
Recall	0.99	0.94	0.98	0.90
F1-Score	0.97	0.97	0.94	0.93
Accuracy (Test)	0.9663		0.9403	
CV Accuracy (10-fold)	0.9633 ± 0.0117		0.9432 ± 0.0192	
AUC-ROC	0.0162*	0.9838	0.9775	0.9775
Falsos Positivos (FP)	4		8	
Falsos Negativos (FN)	22		40	

Discusión de Resultados

Ambos modelos lograron un desempeño sólido en la clasificación de malware, pero al comparar sus métricas en detalle el Modelo 1 (TF-IDF + Random Forest) se posiciona como superior al Modelo 2 (Gemini Embeddings + Red Neuronal) en los aspectos más relevantes para esta tarea. En accuracy general, el Modelo 1 alcanzó 96.63% en prueba frente al 94.03% del Modelo 2, y su validación cruzada de 10 folds ($96.33\% \pm 1.17\%$ vs $94.32\% \pm 1.92\%$) refleja además mayor estabilidad y consistencia entre particiones, lo que sugiere una mejor capacidad de generalización.

La métrica más determinante en ciberseguridad es el Recall de la clase Malware, pues un falso negativo implica que una amenaza real pasa desapercibida. En este aspecto el Modelo 1 es notoriamente superior: obtuvo un Recall de 0.9429, produciendo solo 22 falsos negativos, frente al Recall de 0.8961 del Modelo 2, que dejó pasar 40 muestras maliciosas. Esta diferencia de 18 amenazas adicionales detectadas tiene un impacto operacional directo en un entorno real. En cuanto a falsos positivos, el Modelo 1 también es más preciso con solo 4 frente a 8 del

Modelo 2, y su AUC-ROC de 0.9838 supera levemente al 0.9775 del Modelo 2, consolidando su ventaja discriminatoria.

Algo que aporta mucho a esto es la interpretabilidad. El Modelo 1 permite identificar cuáles API calls tienen mayor peso en la clasificación, lo que facilita la comprensión del comportamiento malicioso y la auditoría del sistema. El Modelo 2, en cambio, depende de llamadas externas a la API de Gemini para generar embeddings, lo que introduce mayor latencia, costo computacional y dependencia de conectividad, factores limitantes en entornos de producción.

En conclusión, el Modelo 1 (TF-IDF + Random Forest) detecta mejor el malware en este dataset. Su superioridad en recall, falsos negativos, accuracy y estabilidad lo convierte en la opción más confiable. Esto es porque las API calls constituyen un vocabulario técnico y simbólico en la que la señal discriminatoria se encuentra en la frecuencia y combinación de llamadas específicas, información que TF-IDF captura de forma eficiente, mientras que los embeddings semánticos de Gemini, diseñados para lenguaje natural, no ofrecen una ventaja clara en este contexto.